

Data Engineering pour l'intelligence artificielle

Responsable du cours

· SHEIKH Rakib

Responsable pédagogique

· ARIB Souhila

- **Code cours :**
- **Promotion :** CY TECH : INGENIEUR 3 OPTION INTELLIGENCE ARTIFICIELLE
- **Année :** 2025 — 2026

Présentation du cours :

La discipline du Big Data est fondamentale pour alimenter les systèmes d'information décisionnels, que ce soit en temps réel ou en différé. Cette discipline est maîtrisée principalement par les Data Engineers. Cependant, elle reste une base essentielle à la fois pour l'entraînement d'un modèle d'intelligence artificielle et pour la restitution des données sous forme de visualisation.

Aujourd'hui, les Data Engineers maîtrisent deux langages de programmation : Python et Scala. Le focus de ce cours sera essentiellement porté sur le langage Scala, très utilisé dans la fintech et le secteur bancaire.

Objectif pédagogiques

- Être capable de construire une pipeline de données hétérogène en langage Scala à travers Apache Spark.
- Être capable de manipuler des bases de données de type Apache Hadoop HDFS ainsi que le protocole universel S3.
- Être capable de réutiliser les résultats de travaux d'ingénierie des données à des fins d'entraînement d'un modèle de machine learning expérimental.
- Consolider les notions de programmation fonctionnelle appliquées à l'ingénierie des données.

Méthodologie utilisé :

- Travaux pratiques sur l'utilisation de hdfs et du protocole S3.
- Remise à niveau en Scala version 2.13 à partir de connaissances antérieures en Java, sous la forme de tests unitaires autonomes.
- Évaluation sous la forme d'un projet de conception d'architecture décisionnelle de bout en bout comprenant :
 - la collecte des données ainsi que leur stockage via le protocole S3.
 - le nettoyage des données selon les standards de qualité définis dans les spécifications techniques.
 - la mise à disposition d'un modèle de machine learning réutilisant les données traitées.

Programme détaillé :

1. Séance 1 :
 - Histoire du Big Data et ses enjeux actuels
 - Écosystème Hadoop
2. Séance 2 : Au choix
 - Soit une séance de remise à niveau en Scala
 - Soit une introduction à Apache Spark (section RDD)
3. Séance 3 : Au choix dépendant de la séance précédente:
 - Soit une introduction à Apache Spark (section RDD)
 - Soit une introduction à Apache Spark (sections Dataset, DataFrame, SQL et optimisation de requêtes)
4. Séance 4 : Au choix dépendant de la séance précédente :
 - Soit une introduction à Apache Spark (sections Dataset, DataFrame, SQL et optimisation de requêtes)
 - Soit une introduction à Apache Kafka pour le traitement des données en temps réel

Ouvrages de références :

- [Data Algorithms with Spark \(Oreilly\)](#)

- [Big Data Analysis with Spark \(Scala\) - EPFL](#)
- [Functional Programming, Simplified, Alvin Alexander](#)
- [Kafka documentation : Confluent](#)

Outils informatique demandés :

- PC Unix obligatoire afin d'être dans des conditions idéales de développement.
- `sdkman` pour la gestion de versions multiples de Java Temurin et de Scala (non disponible sous Windows).
- IntelliJ IDEA pour Scala. (*La licence étudiante est octroyée sur simple demande à l'éditeur JetBrains avec les adresses CYU*)

Pré-requis pédagogique :

- Niveau avancé du langage Java 17+ (Lambda, Streams) ou Niveau avancé du langage Scala 2.13.x (Fonctionnelle, Lambda, case class, récursion)
- Maîtrise de Docker
- Notion sur le nettoyage de données.
- Maîtrise des requêtes SQL (Filtrage, Jointures essentiellement)
- Bash et systèmes Unix
 - Commandes bash, accès utilisateurs, scripting

Modalités de contrôles de connaissances

Le contrôle de connaissance sera effectué à travers la soumission d'un code source d'un projet.

La constitution d'un groupe est autorisée, la limite maximale d'un groupe est de 5. Il est conseillé aux élèves de garder ce projet sous la main dans le cadre du cours d'architecture micro-services (MLOps), qui aura lieu au second semestre.

Le projet sera mis à disposition à travers un GitHub servant de squelette. Les groupes doivent «forker» le squelette afin d'apporter toutes les modifications nécessaires à la réalisation du projet. Le rendu est sous la forme de pull-request avant la fin de la date limite.

Lors d'un pull request, les agents d'intelligence artificielle vont inspecter les travaux des groupes et leur conseiller dans leur travail sous la forme d'un commentaire. Le suivi de ces conseils est fortement recommandé mais reste optionnel. Les commits peuvent être ajoutés dans une pull-request déjà ouverte, ce qui permet de simuler l'émission d'un feedback dans un environnement agile en entreprise.

Par souci de clarification, l'évaluation des travaux restera toujours manuel, indépendamment des commentaires émis par les agents IA.

En cas d'erreur de notation constatée après la mise à disposition des notes, les groupes ont un délai de deux semaines afin de porter une réclamation de la note auprès du responsable du cours, précisant le motif de la réclamation et si nécessaire une demande de re-correction.

La note à l'issue de la demande de re-correction est finale qu'elle soit bonne ou mauvaise par rapport à la note initiale.